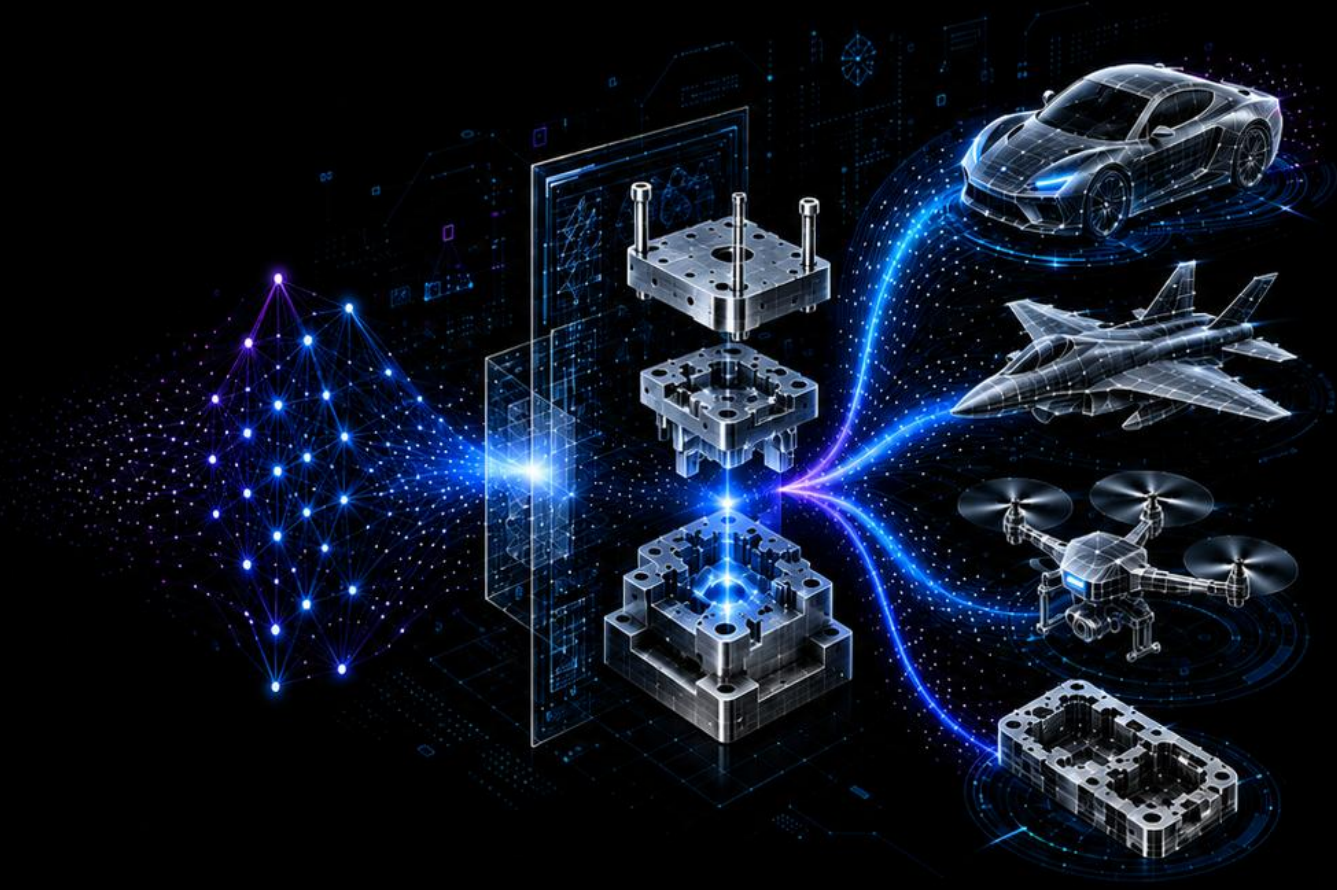
머신 러닝 핵심 알고리즘

지도 학습 & 비지도 학습

하형진
(지도교수: 양선웅)

한양대학교 ERICA 기계공학과



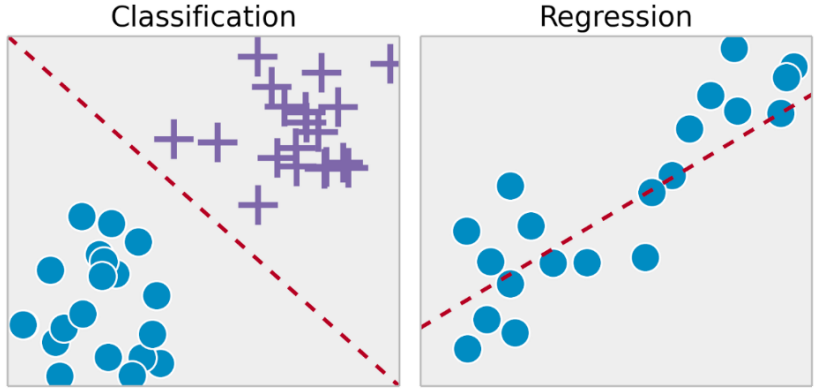
Intelligent Design for Engineering Applications Lab

지도 학습

Part 1 Introduction
Part 2 Method
Part 3 Results & Discussion
Part 4 Conclusion

분류와 회귀

- 지도 학습은 정답을 통해 컴퓨터에 미리 알려 주고 데이터를 학습시키는 방법
- 분류는 주어진 데이터를 정해진 범주(카테고리, Label)에 따라 분류
- 회귀는 데이터들의 특성을 기준으로 연속된 값을 그래프로 표현하여 패턴이나 트렌드를 예측할 때 사용



❖ 분류 (이산형 데이터)

선택한 데이터가 어떤 그룹에 속하는지 예측하는 모델

’ 훈련 데이터의 레이블 중 하나를 예측’

❖ 회귀 (연속형 데이터)

선택한 데이터의 결과값에 가까운 실수값을 예측하는 모델

‘연속된 값을 예측

❖ 분류 분석

범주형 데이터를 예측하는 분석 방법. 주어진 데이터를 특정 카테고리나 클래스로 분류하는 것으로 각 데이터가 어떤 그룹에 속하는지 예측하는 문제

Ex) 스팸 메일, 고객이 우수 고객인지 일반 고객인지

결과 값: 이산형(discrete), “YES”&”NO”, “1”&”0”

❖ 회귀 분석

연속형 데이터를 예측하는 분석 방법. 독립 변수와 종속 변수 간의 관계를 분석하여 수치 값을 예측, 데이터 간의 상관관계를 활용하여 미래의 값을 예측

Ex) 주가 분석 예측, 주택의 크기나 방 개수를 바탕으로 주택 가격을 예측

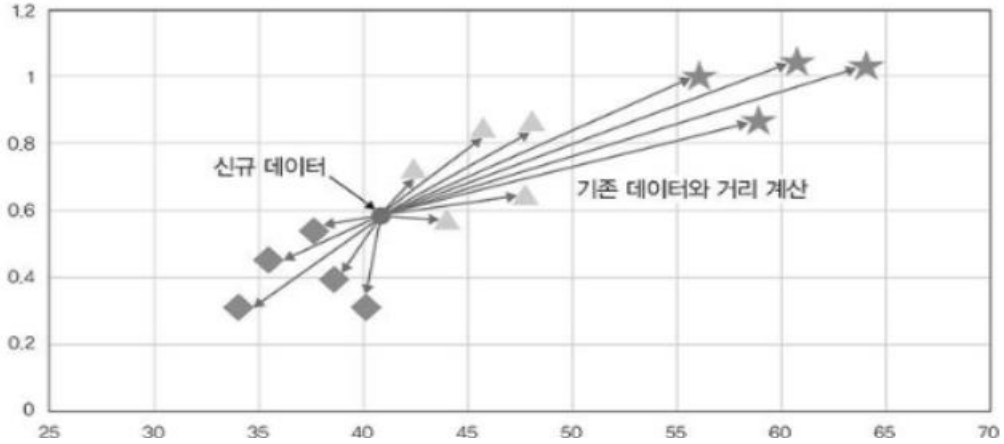
결과 값: 연속형(continuous), 100,200 같은 수치 값을 예측

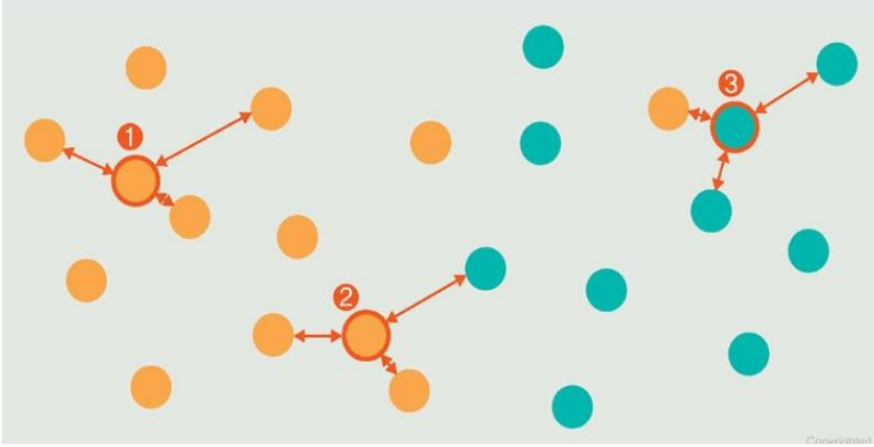
지도 학습

Part 1 Introduction
Part 2 Method
Part 3 Results & Discussion
Part 4 Conclusion

K-최근접 이웃

- 새로운 입력을 받았을 때 기존 클러스터에서 모든 데이터와 인스턴스 기반 거리를 측정한 후 가장 많은 속성을 가진 클러스터에 할당하는 분류 알고리즘, 과거 데이터를 사용하여 미리 기준(규칙)을 만드는 것이 아니라 과거 데이터를 저장해 두고 필요할 때마다 비교를 수행하는 방식





❖ 관련 개념

K 값: 몇 개의 이웃을 참고할건지

클러스터링: 서로 비슷한 성격을 가진 데이터들끼리 묶어 하나의 그룹으로 분류

클러스터: 유사한 특성을 가진 데이터들의 집단

인스턴스: 새로운 데이터가 들어 왔을 때 데이터와 데이터 사이의 거리를 측정한 관측치

새로운 입력 1, 2, 3에 대한 학습 절차 (K=3)

❖ 새로운 입력 1

주변 범주 세 개가 주황색이므로 주황으로 분류

❖ 새로운 입력 2

주변 범주 두 개가 주황색, 한 개가 녹색이므로 주황으로 분류

❖ 새로운 입력 3

주변 범주 두 개가 녹색, 한 개가 주황색이므로 녹색으로 분류

Part 1 Introduction
Part 2 Method
Part 3 Results & Discussion
Part 4 Conclusion

K-최근접 이웃

```
from sklearn.metrics import accuracy_score
y_pred = knn.predict(X_test)
print("정확도: {}".format( accuracy_score(y_test, y_pred)))
```

```
정확도: 0.8333333333333334
```

```
from sklearn.metrics import accuracy_score
y_pred = knn.predict(X_test)
print("정확도: {}".format( accuracy_score(y_test, y_pred)))
```

```
정확도: 0.8666666666666667
```

```
from sklearn.metrics import accuracy_score
y_pred = knn.predict(X_test)
print('모델 정확도: {}'.format(accuracy_score(y_test, y_pred)))
```

```
출력결과 : 모델 정확도: 0.9333333333333333
```

train_test_split()은 데이터를 무작위(Random)로 분할

따라서 코드를 실행할 때마다 학습 데이터와 테스트 데이터 구성이 달라질 수 있으며, 그에 따라 정확도도 조금씩 달라질 수 있다.

```
k=10
acc_array=np.zeros(k)
for k in np.arange(1,k+1,1):
    classifier = KNeighborsClassifier(n_neighbors=k).fit(X_train,y_train)
    y_pred = classifier.predict(X_test)
    acc = metrics.accuracy_score(y_test, y_pred)
    acc_array[k-1]=acc

max_acc=np.amax(acc_array)
acc_list=list(acc_array)
k=acc_list.index(max_acc)
print("정확도 ", max_acc, "으로 최적의 k는", k+1, "입니다.")
```

```
정확도  0.9666666666666667 으로 최적의 k는 1 입니다.
```

❖ Cross Validation(교차 검증)

여러 차례 실행한 후 평균을 찾는 것이 좋다. (학습&평가 반복)

• 과대 적합 방지

하나의 고정된 테스트 데이터에만 맞춰지는 것을 막는다.

• 데이터 편향성 최소화

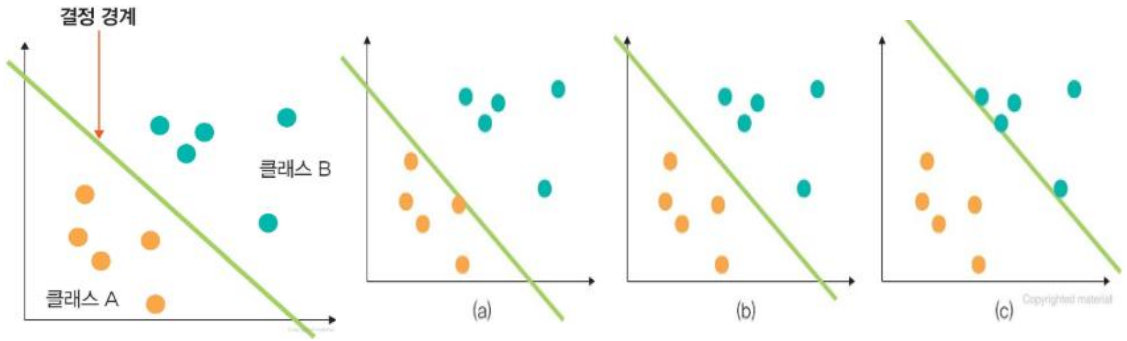
데이터 쏠림 현상을 방지하여 새로운 데이터에서도 잘 동작하는지 정확히 파악

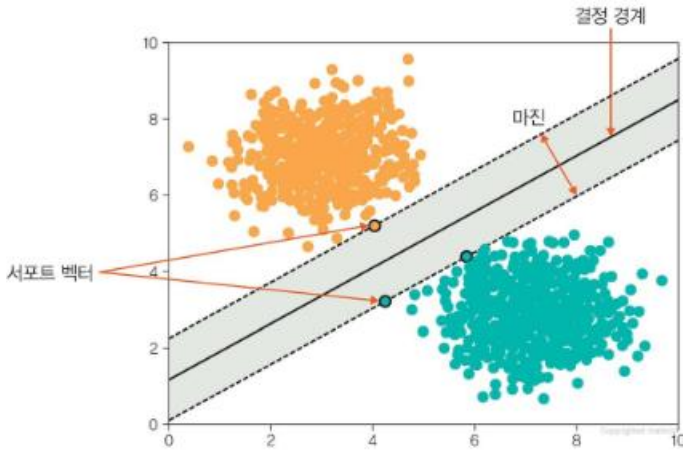
• 제한된 데이터의 효율적 활용

적은 양의 데이터셋에서도 학습과 검증을 모두 수행할 수 있어 유용

서포트 벡터 머신

- 분류를 위한 기준선을 정의하는 모델
- 분류되지 않은 새로운 데이터가 나타나면 결정 경계(기준선)를 기준으로 경계의 어느 쪽에 속하는지 분류





❖ 결정 경계

데이터를 분류하기 위한 기준선

❖ 마진

결정 경계와 서포트 벡터 사이의 거리

❖ 서포트 벡터

결정 경계와 가까이 있는 데이터들

→ 최적의 결정 경계는 마진을 최대로 해야 함

데이터들을 올바르게 분리하면서 마진 크기를 최대화해야 함

결국 이상치(패턴에서 벗어난 값)를 잘 다루는 것이 중요

❖ 하드 마진

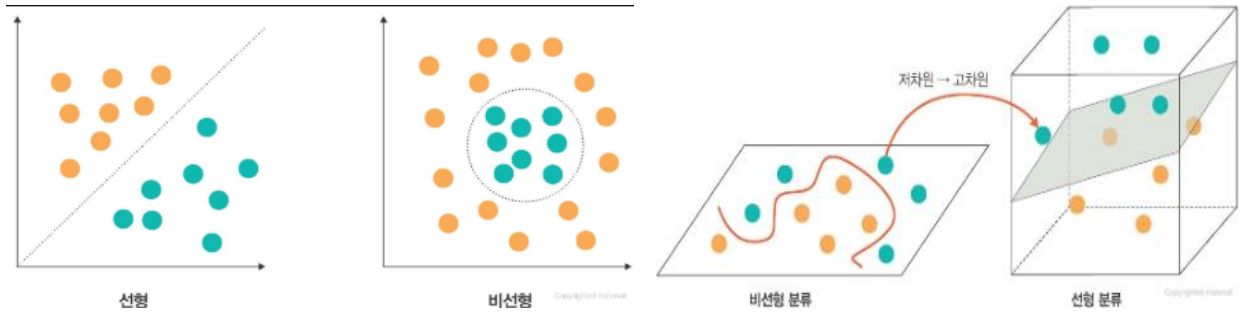
이상치를 허용하지 않는 것

❖ 소프트 마진

어느 정도의 이상치들이 마진 안에 포함되는 것을 허용

Part 1 Introduction
Part 2 Method
Part 3 Results & Discussion
Part 4 Conclusion

서포트 벡터 머신



$K(a,b) = a^T \cdot b$
$(a, b$: 입력벡터$)$

$(a,b) = (\gamma a^T \cdot b)^d$
$(a, b$: 입력벡터
γ : 감마
d : 차원, 이때γ, d는하이퍼파라미터$)$

$K(a,b) = exp(-\gamma \|a-b\|^2)$
$($이때γ는하이퍼파라미터$)$

- ❖ 선형 커널(For 선형 모델)
- ❖ 다항식/가우시안 커널 (For 비선형 모델)

벡터 내적을 계산한 후
고차원으로 보내는 방법으로
연산량을 줄인 수학적 기교

- ❖ C 값: 오류를 어느 정도 허용할지
- ❖ 감마: 결정 경계를 얼마나 유연하게 가져갈지

SVM은 선형 분류와 비선형 분류를 지원

❖ 저차원 데이터/고차원 데이터

특성이 적은 데이터/특성이 많은 데이터

❖ 커널

데이터를 비선형 공간에서 선형 분리가 가능한 고차원 공간으로 매핑해주는 수학적 함수

❖ 커널 트릭

저차원에서 고차원으로 데이터를 보낼 때 많은 수학적 계산이 필요하기 때문에 성능에 문제를 줄 수 있는데 이를 해결하고자 도입한 것

❖ 선형 커널

선형으로 분류 가능한 데이터에 적용

선형 커널은 기본 커널 트릭으로 커널 트릭을 사용하지 않음

❖ 다항식 커널

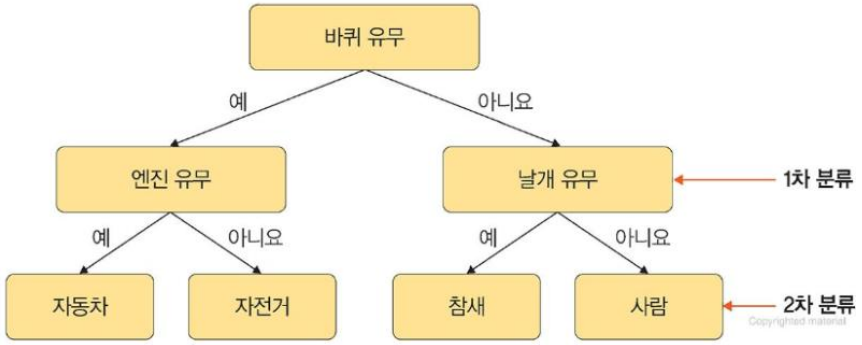
실제로는 특성 추가 X, 다항식 특성을 많이 추가한 것과 같은 결과를 얻을 수 있는 방법 (고차원으로 데이터 매핑 가능)

❖ 가우시안 RBF 커널

다항식 커널의 확장, 다항식 커널과는 달리 차수 제한 없이 무한한 확장 가능

결정 트리

- 데이터를 분류하거나 결과값을 예측하는 분석 방법
- 결과 모델이 트리 구조





$$Entropy(A) = -\sum_{k=1}^{m} p_k \log_2(p_k)$$

(P_k=A 영역에 속하는 데이터 가운데 k 범주에 속하는 데이터 비율)

엔트로피 = 0 = 불확실성 최소 = 순도 최대

엔트로피 = 0.5 = 불확실성 최대 = 순도 최소

$$Entropy(A) = -(\frac{1}{4})\log(\frac{1}{4}) - (\frac{3}{4})\log(\frac{3}{4})$$
$$= \frac{2}{4} + \frac{3}{4} \times 0.42$$
$$= 0.31$$

$$G(S) = 1 - \sum_{i=1}^{c} p_i^2$$

(S: 이미 발생한 사건의 모음, c: 사건 개수)

데이터를 1차로 분류한 후 각 영역의 순도는 증가하고
불순도와 불확실성은 감소하는 방향으로 학습을 진행

❖ 순도

범주 안에서 같은 종류의 데이터만 모여 있는 상태

❖ 불순도

서로 다른 데이터가 섞여 있는 상태

결정 트리에서 불확실성을 계산하는 방법 = 엔트로피/지니계수

❖ 엔트로피

확률 변수의 불확실성을 수치로 나타낸 것

엔트로피가 높을 수록 불확실성이 높다

❖ 지니 계수

불순도를 측정하는 지표로 데이터의 통계적 분산 정도를
정량화해서 표현한 값

원소 n개 중에서 임의로 두 개를 추출했을 때, 추출된 두 개가
서로 다른 그룹에 속해 있을 확률을 의미

혼동 행렬(결정 트리)

- 알고리즘 성능 평가에 사용 (훈련 결과가 제대로 나왔는지)

		예측 값	
		Positive	Negative
실제 값	Positive	TP	FN
	Negative	FP	TN

- True Positive: 모델(분류기)이 '1'이라고 예측했는데 실제 값도 '1'인 경우
- True Negative: 모델(분류기)이 '0'이라고 예측했는데 실제 값도 '0'인 경우
- False Positive: 모델(분류기)이 '1'이라고 예측했는데 실제 값은 '0'인 경우
- False Negative: 모델(분류기)이 '0'이라고 예측했는데 실제 값은 '1'인 경우

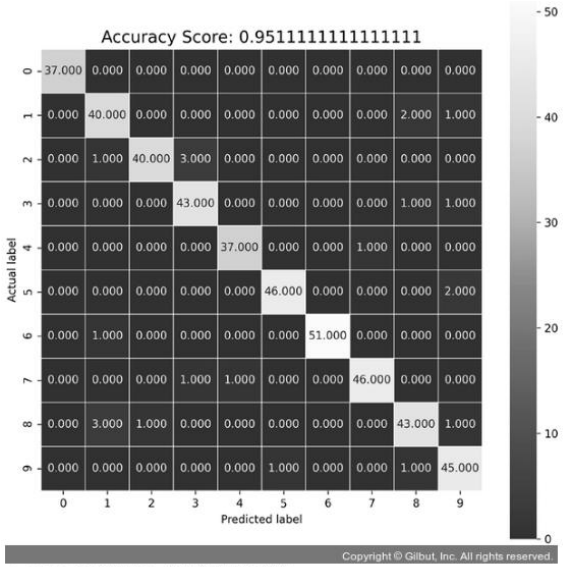
	Predicted Not Survival	Predicted Survival
True Not Survival	99	13
True Survival	16	51

❖ 결정 트리

주어진 데이터를 사용하여 트리 형식으로 데이터를 이진 분류(0 혹은 1)해 나가는 방법

❖ 랜덤 포레스트

결정 트리를 여러 개 묶어 놓아 좀 더 확대한 것



▲ 그림 3-21 로지스틱 회귀 예제 실행 결과

❖ 결과를 확인하기는 좋지만, 직관적으로 이해하기는 난해. 혼동 행렬은 단지 결과 확인용으로 사용하는 것을 권장

지도 학습

로지스틱 회귀(확률을 예측하여 특정 범주로 분류하기 위해)

- 독립 변수(예측 변수): 영향을 미칠 것으로 예상되는 변수, ex) 키
- 종속 변수(기준 변수): 영향을 받을 것으로 예상되는 변수, ex) 몸무게

데이터가 100개라면 확률은 모두 곱한다. 하지만 100개를 곱하면 너무 작아져 계산하기 어렵기 때문에 로그를 사용

log(ab)=log(a)+log(b), 확률 곱하기가 확률 더하기가 되어 쉬워짐

언더플로(산술 연산 결과가 취급할 수 있는 수의 범위보다 작아지는 상태) 방지

구분	일반적인 회귀 분석	로지스틱 회귀 분석
종속 변수	연속형 변수	이산형 변수
모형 탐색 방법	최소제곱법	최대우도법
모형 검정	F-테스트, t-테스트	X2 테스트

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

$$\theta_{ml} = \arg\max_{\theta} P_{\text{model}}(Y \mid X;\theta) \quad \text{①}$$

$$\theta_{ml} = \arg\max_{\theta} \sum_{i=1}^{m} \log P_{\text{model}}(y_i \mid x_i;\theta) \quad \text{②}$$

❖ 최소제곱법

오차의 제곱합이 가장 작은 선을 찾는 것

(실제 값에서 예측 값을 뺀 후 제곱한 값들의 평균)

❖ 최대우도법

지금 가진 이 데이터들이 나타날 가능성(우도)이 가장 높은 상황을 찾는 것

❖ 최대 우도법 식

Θ: 파라미터(가중치, 편향)

arg max: 가장 큰 값을 만들어주는 변수

(확률을 가장 크게 만드는 Θ를 찾는 것)

입력 X가 주어졌을 때 실제 정답 Y가 나올 확률을 가장 크게 만드는 파라미터를 찾는 것)

❖ 로지스틱 회귀

분석하고자 하는 대상들이 두 집단 혹은 그 이상의 집단으로 나누어진 경우, 개별 관측치들이 어느 집단으로 분류 될 수 있는지 분석하고 예측 (특정 범주에 속할 확률)

- **1단계**: 각 집단에 속하는 확률의 추정치를 예측합니다. 이때 추정치는 이진 분류의 경우 집단 1에 속하는 확률 $P(Y=1)$로 구합니다.
- **2단계**: 분류 기준 값(cut-off)을 설정한 후 특정 범주로 분류합니다.

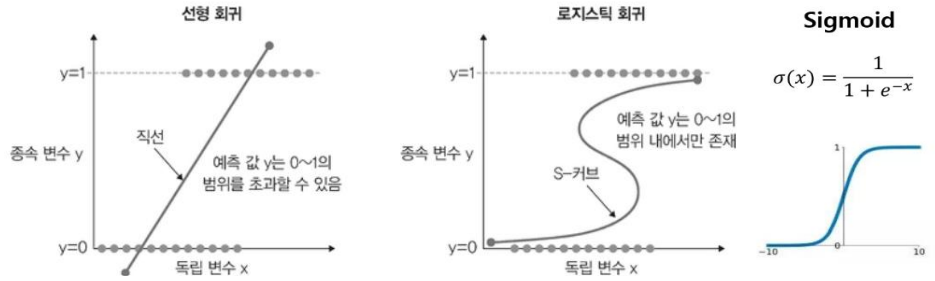
예 $P(Y=1) \geq 0.5 \rightarrow$ 집단 1로 분류

$P(Y=1) < 0.5 \rightarrow$ 집단 0으로 분류

지도 학습

선형 회귀

- 독립 변수 x를 사용하여 종속 변수 y의 움직임을 예측하고 설명하는데 사용
- 종속 변수와 독립 변수의 관계를 설정하는데 사용



❖ 단순 선형 회귀

하나의 x값으로 y값을 설명

❖ 다중 선형 회귀

여러 개의 x값으로 y값을 설명

❖ 독립 변수가 변경되었을 때 종속 변수를 추정

아이스크림 시간 당 100개 판매 y=100x, 아이스크림 가격이 1000원이면 시간 당 10만원의 매출 (변수 값 추정)

반면 로지스틱 회귀는 사건의 확률(0또는1)을 확인하려고 사용

❖ 최대 우도법 식

Θ: 파라미터(가중치, 편향)

arg max: 가장 큰 값을 만들어주는 변수

(확률을 가장 크게 만드는 Θ를 찾는 것)

입력 X가 주어졌을 때 실제 정답 Y가 나올 확률을 가장 크게 만드는 파라미터를 찾는 것)

❖ 로지스틱 회귀

분석하고자 하는 대상들이 두 집단 혹은 그 이상의 집단으로

나누어진 경우, 개별 관측치들이 어느 집단으로 분류 될 수 있는지 분석하고 예측 (특정 범주에 속할 확률)

- **1단계**: 각 집단에 속하는 확률의 추정치를 예측합니다. 이때 추정치는 이진 분류의 경우 집단 1에 속하는 확률 $P(Y=1)$로 구합니다.
- **2단계**: 분류 기준 값(cut-off)을 설정한 후 특정 범주로 분류합니다.

예 $P(Y=1) \geq 0.5 \rightarrow$ 집단 1로 분류

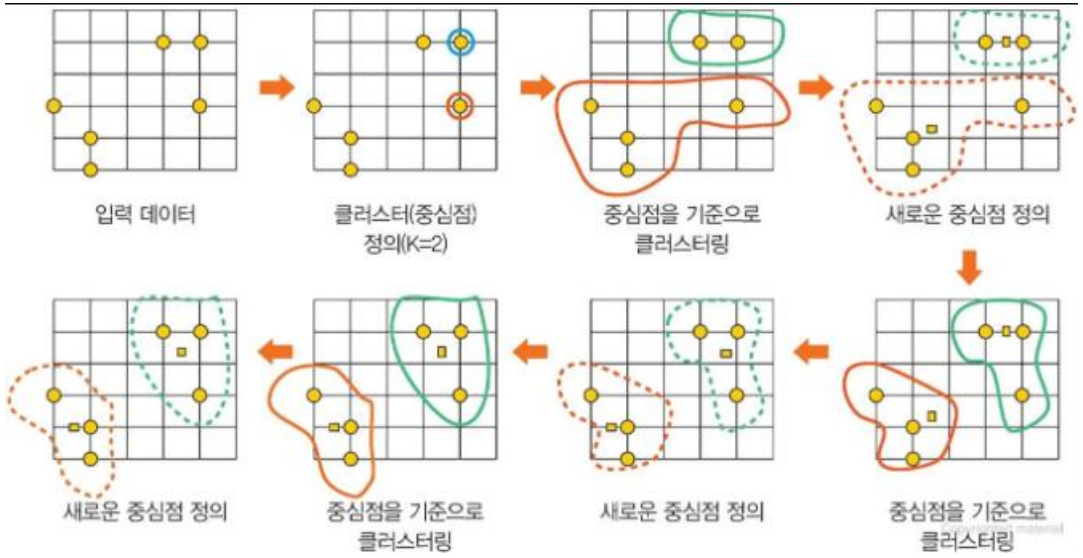
$P(Y=1) < 0.5 \rightarrow$ 집단 0으로 분류

비지도 학습

군집과 차원 축소

- 비지도 학습은 정답이 없는 상태에서 훈련시키는 방식
- 군집은 데이터의 유사성을 측정한 후 유사성이 높은 데이터끼리 집단으로 분류
- 차원 축소는 차원을 나타내는 특성을 줄여서 데이터를 줄이는 방식

구분	군집	차원 축소
목표	데이터 그룹화	데이터 간소화
주요 알고리즘	K-평균 군집화(K-Means)	주성분 분석(PCA)
예시	사용자의 관심사에 따라 그룹화하여 마케팅에 활용	• 데이터 압축 • 중요한 속성 도출



❖ K-평균 군집화 비추천 상황

1. 데이터가 비선형 일때
2. 군집 크기가 다를 때
3. 군집마다 밀집도와 거리가 다를 때

❖ K-평균 군집화 (K=2)

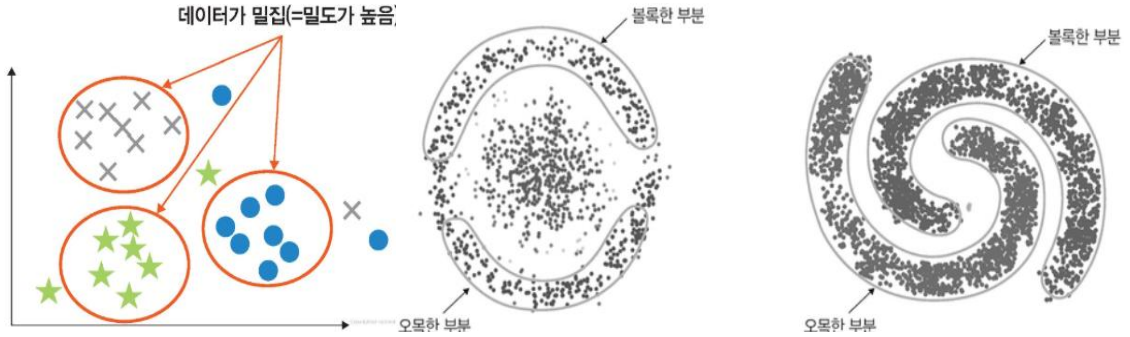
데이터를 입력받아 소수의 그룹으로 묶는 알고리즘

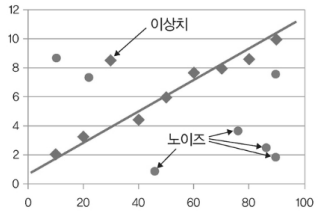
1. 중심점 선택: 랜덤하게 초기 중심점을 선택
2. 클러스터 할당: K개의 중심점과 각각의 개별 데이터 간의 거리를 측정한 후 가장 가까운 중심점을 기준으로 데이터를 할당(클러스터가 구성)
3. 새로운 중심점 선택: 클러스터마다 새로운 중심점을 계산
4. 범위 확인: 선택된 중심점에 더 이상의 변화가 없다면 진행을 멈춤
5. 만약 계속 변화가 있다면 2~3 과정을 반복

비지도 학습

밀도 기반 군집 분석

- 일정 밀도 이상을 가진 데이터를 기준으로 군집을 형성하는 방법
- 노이즈에 영향을 받지 않으며 K-평균 군집화에 비해 연산량은 많지만, 오목하거나 볼록한 부분을 처리하는 데 유용





노이즈는 주어진 데이터셋과 무관하거나 무작위성 데이터로 전처리 과정에서 제거해야 할 부분입니다. 이상치는 관측된 데이터 범위에서 많이 벗어난 아주 작은 값이나 아주 큰 값을 의미합니다.

❖ 단순 선형 회귀

하나의 x값으로 y값을 설명

❖ 다중 선형 회귀

여러 개의 x값으로 y값을 설명

❖ 독립 변수가 변경되었을 때 종속 변수를 추정

아이스크림 시간 당 100개 판매 y=100x, 아이스크림 가격이 1000원이면 시간 당 10만원의 매출 (변수 값 추정)

반면 로지스틱 회귀는 사건의 확률(0또는1)을 확인하려고 사용

1단계: 엡실론 내 점 개수 확인 및 중심점 결정

Ex) P1(중심점)/minPts=3, P1을 중심으로 엡실론 내에 점이 세 개 이상 있으면 하나의 군집으로 판단

2단계: 군집 확장

데이터의 밀도 기반으로 군집을 생성하기 때문에 밀도가 높은 지역에서 중심점을 만족하는 데이터가 있다면 그 지역을 포함하여 새로운 군집 생성

3단계: 1~2단계 반복

데이터가 밀집된 밀도가 높은 지역에서 더 이상 중심점을 정의할 수 없을 때까지 1~2단계를 반복

4단계: 노이즈 정의

어떤 군집에도 포함되지 않은 데이터를 노이즈로 정의

Part 1 Introduction
Part 2 Method
Part 3 Results & Discussion
Part 4 Conclusion

주성분 분석(PCA)

- 고차원 데이터를 저차원으로 축소시켜 데이터가 가진 대표 특성만 추출 (성능 향상, 작업 간편해짐)
- 차원 축소 알고리즘

❖ PCA를 왜 사용할까?

변수가 많아지면 그래프도 보기 어렵고 계산도 오래 걸리고 중요하지 않은 변수도 많다.

그래서 중요한 정보만 남기고 변수 개수를 줄이고자 사용

❖ 핵심

PCA의 목적

: 차원을 줄이면서 중요한 정보를 최대한 유지하는 것

e1(제1주성분)

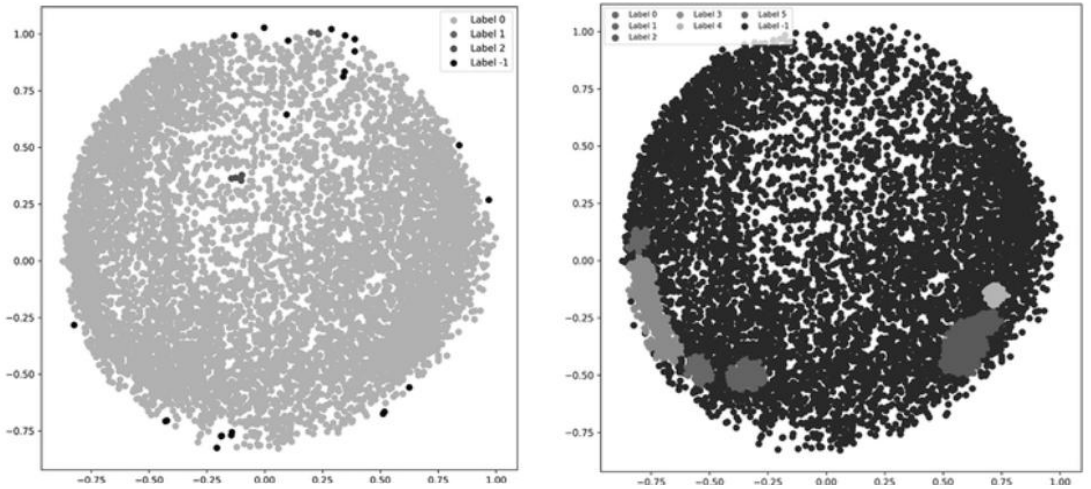
: 데이터가 가장 많이 퍼져 있는 방향(가장 중요한 정보)

e2(제2주성분)

e1과 직각이며 두 번째로 중요한 방향

PCA 결과

: 원래 변수를 새로운 변수로 변환하여 필요한 주성분만 남겨 차원을 축소



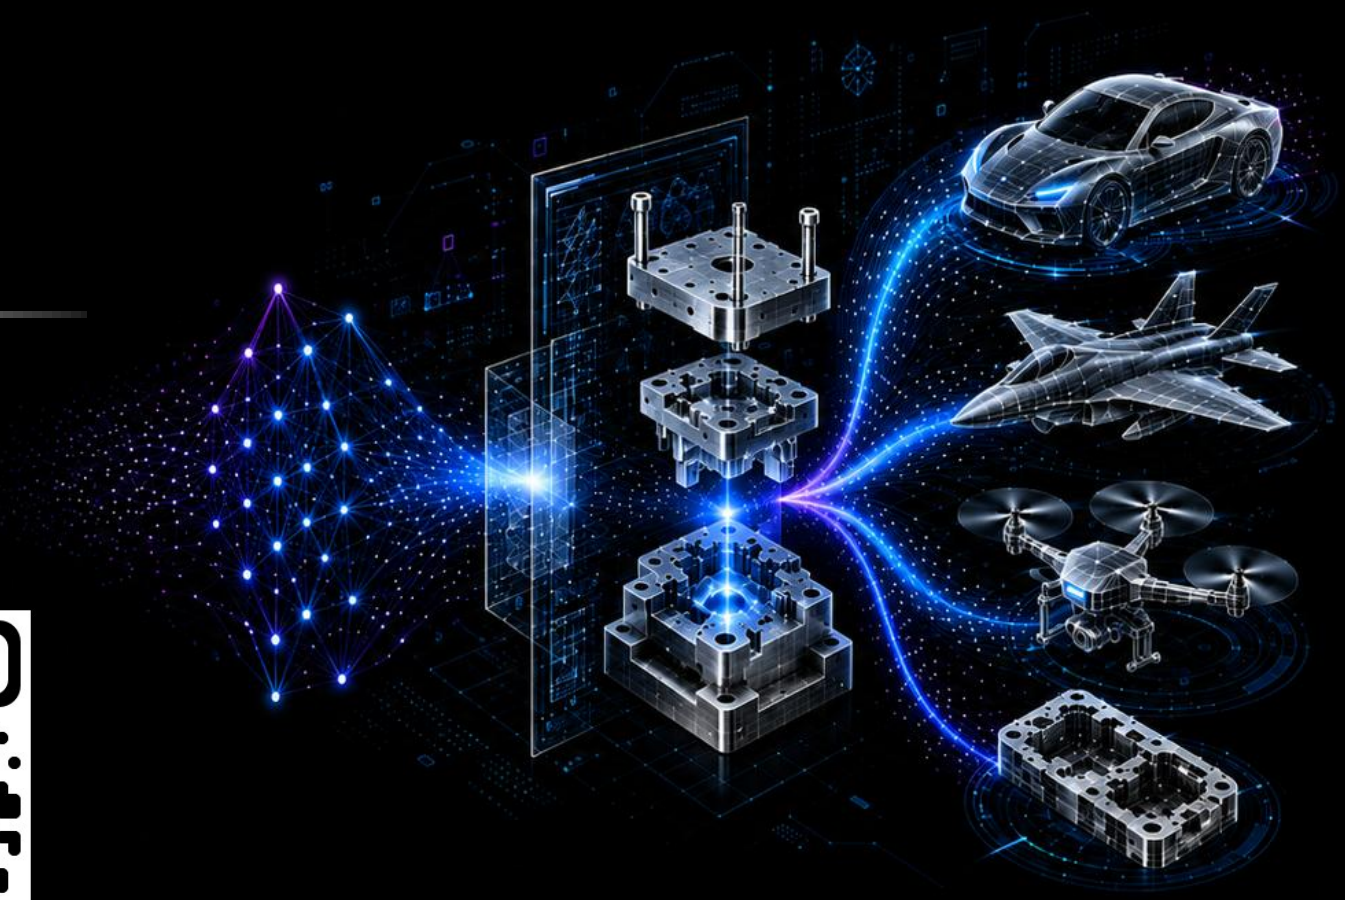
minPts의 하이퍼파라미터를 3에서 50으로 변경한 후 군집이 더 향상되어 표현 된 것을 확인

주성분

: 전체 데이터(독립 변수들)의 분산을 가장 잘 설명하는 성분

Ex) 전체 독립 변수가 네 개 있는데, 두 개의 변수로도 전체 데이터에 대한 분산을 충분히 설명할 수 있다면 두 개의 변수만 사용하겠다는 의미

Any Questions?



이름 하 형 진

소속 한양대학교 IDEA LAB

이메일 broha@hanyang.ac.kr

Intelligent Design for Engineering Applications Lab