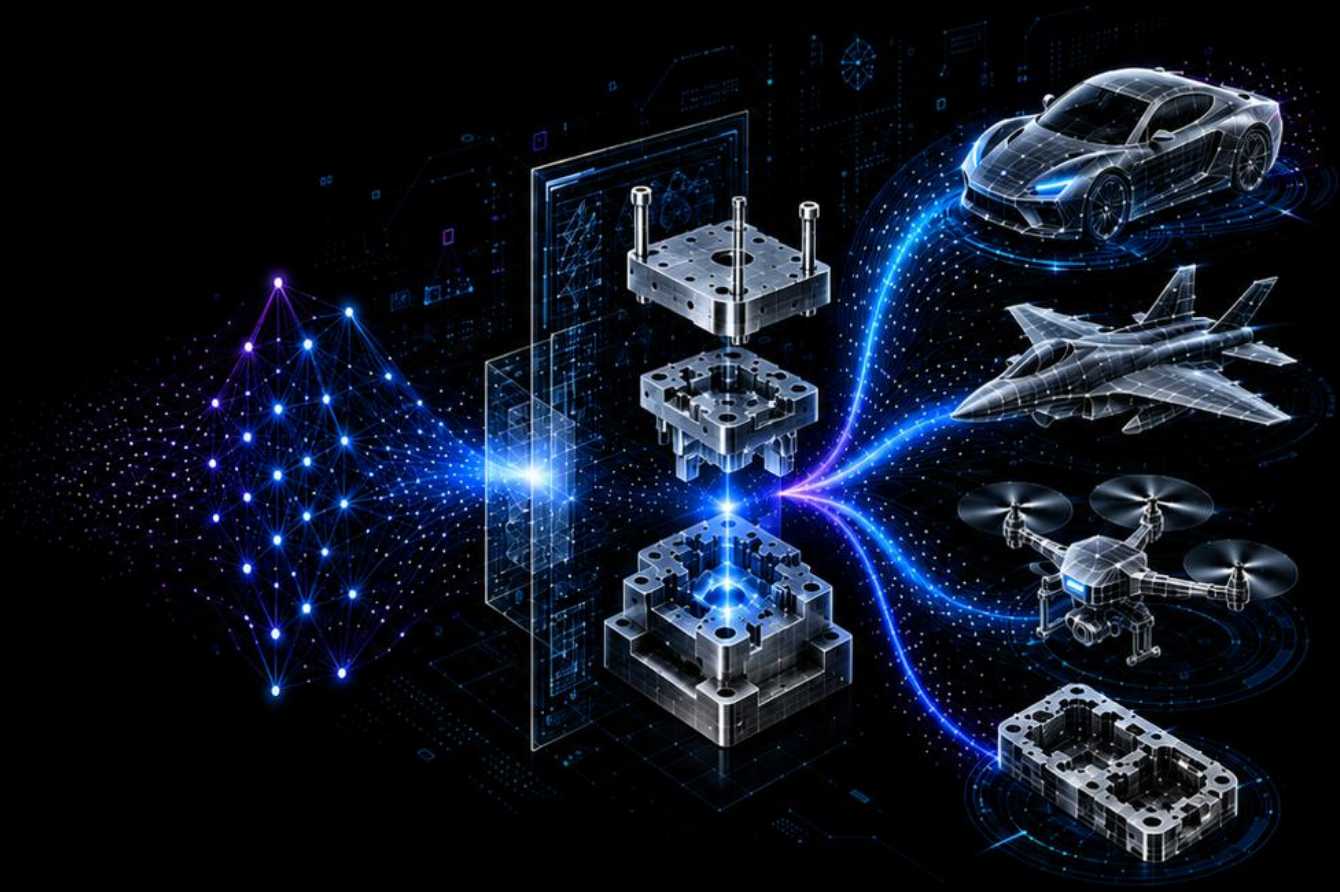
IDEA LAB AI STUDY

CNN



하형진

(지도교수: 양선웅)

한양대학교 ERICA 기계공학과

Intelligent Design for Engineering Applications Lab

Part 1 Introduction

Part 2 Method

Part 3 Results & Discussion

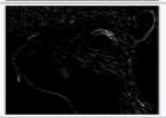
Part 4 Conclusion

Image Processing and Filtering Techniques

❖ 행렬로 표현된 필터링된 이미지의 i번째 행, j번째 열의 픽셀인 G_{ij}는 원본 이미지 X와 필터 F의 합성곱으로 계산된다.

$$G_{ij} = (F * X)(i,j) = \sum_{m=0}^{F_H-1} \sum_{n=0}^{F_W-1} F_{m,n} X_{(i-m),(j-n)}.$$

위의 식에서 F_H와 F_W는 각각 필터의 높이 (행의 수)와 너비 (열의 수)

Operation	Filter	Filtered image
Identity	$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$	
Edge detection	$\begin{bmatrix} 1 & 0 & -1 \\ 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix}$	
	$\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$	
	$\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$	
Sharpen	$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$	
Box blur (normalized)	$\frac{1}{9}\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$	

❖ Identity

필터 가운데만 1, 현재 픽셀만 그대로 가져옴 (원본 이미지 그대로)

❖ Edge Detection

가운데 큰 양수, 주변은 음수, 주변과 차이가 큰 부분만 강하게 남김

따라서 윤곽선만 보이게 됨

❖ Sharpen

현재 픽셀은 5배, 주변은 빼줌으로서 윤곽이 더 뚜렷해짐 (선명)

❖ Box Blur

9개의 값을 모두 더한 뒤 9로 나눔 = 평균을 구하는 것

즉 이미지가 부드러워지는 걸 Blur라고 함

일반 이미지 처리에서는 윤곽선, 블러, 선명화 등 필터를

직접 설계하지만 CNN에서는 필터를 AI가 학습하여

눈, 코, 귀, 바퀴 등을 찾는 필터를 자동으로 만들어냄

그래서 CNN이 이미지 인식에 강함

Part 1 Introduction

Part 2 Method

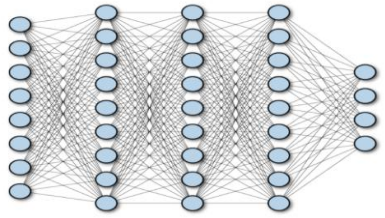
Part 3 Results & Discussion

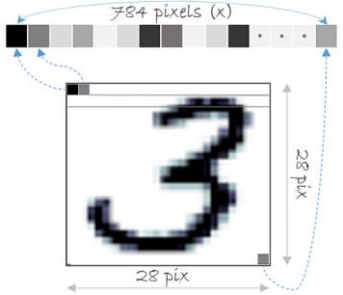
Part 4 Conclusion

Convolutional Neural Network

- CNN은 음성 인식이나 이미지/영상 인식에서 주로 사용되는 신경망, 다차원 배열 데이터를 처리하도록 구성되어 컬러 이미지 같은 다차원 배열 처리에 특화

❖ Fully-connected layer

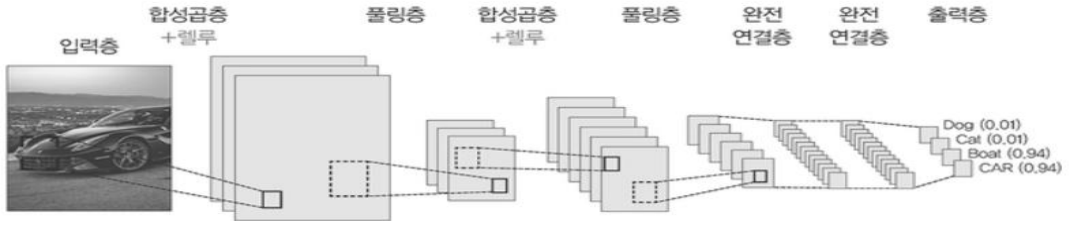




: 일반적인 DNN구조, 이전 층의 뉴런들과 다음층의 뉴런들이 하나도 빠짐없이 서로 연결되어 있는 구조

- 완전연결계층의 문제점은 '데이터의 형상이 무시'된다는 점
- 이미지 데이터의 경우 3차원(세로, 가로, 채널)의 형상을 가지며, 이 형상에는 공간적 구조를 가진다. 이미지 분석은 이미지 배열을 펼쳐서 (flattening) 입력되는데 이때 공간적인 정보들을 잃게 된다.
- 완전연결계층의 입력할 때는 3차원 데이터를 1차원 데이터로 평탄화 해줘야 함
- 공간적으로 가까운 픽셀은 값이 비슷하거나, RGB의 각 채널은 서로 밀접하게 관련되어 있거나, 거리가 먼 픽셀끼리는 관련이 없는 등, 이미지 데이터는 3차원 공간에서 이러한 정보들이 내포 되어있다. 하지만, 완전연결계층에서 1차원의 데이터로 펼치게 되면 이러한 정보들이 사라지게 된다.

❖ Convolutional Neural Network



: 이미지, 영상처럼 그리드 형태의 시각 데이터를 처리하기 위한 딥러닝 모델

- 이미지 인식, 개체 감지, 분류 작업에 사용
- 이미지 내의 패턴, 모양, 개체를 자동으로 감지하고 인식
- 공간적 불변성을 가지고 있어 이미지 속 위치, 방향에 관계없이 개체 인식
- 특징 추출에 뛰어나며 입력 데이터에서 복잡하고 추상적인 특징 학습
- 매개변수를 공유(필터)하여 계산 및 메모리 요건이 줄어들어 효율성 향상
- 풀링이나 어댑티브 풀링을 이용하여 마지막 출력 크기를 맞출 수 있어서 다양한 크기의 이미지를 사용할 수 있음

Part 1 Introduction

Part 2 Method

Part 3 Results & Discussion

Part 4 Conclusion

Convolutional Neural Network

Structure

❖ Input layer

입력 이미지 데이터가 최초로 거치게 되는 계층

❖ Convolution layer

입력 데이터에서 특성을 추출하는 역할

❖ Pooling layer

합성곱층과 유사하게 특성 맵의 타원을 다운 샘플링하여 연산량을 감소, 주요한 특성 벡터를 추출하여 학습을 효과적으로 할 수 있게 함

❖ Fully connected layer

합성곱층과 풀링층을 거치면서 차원이 축소된 특성 맵은 최종적으로 완전연결층으로 전달, 이미지는 3차원 벡터에서 1차원 벡터로 펼쳐짐

❖ Output layer

입력받은 값을 0~1 사이의 값으로 출력, 마지막 출력층의 소프트맥스 함수를 사용하여 이미지가 각 레이블에 속할 확률 값이 출력되고 이때 가장 높은 확률 값을 갖는 레이블이 최종 값으로 선정

Tip

❖ Stride

필터를 적용하는 위치의 간격(이동량)

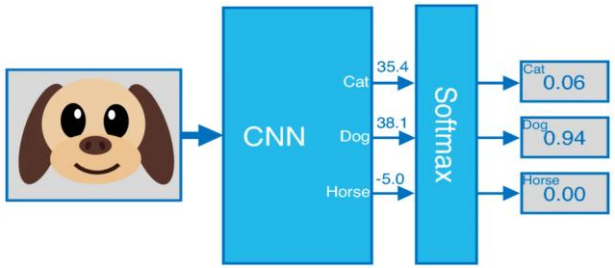
$$\begin{bmatrix}0&1&7&5\\5&5&6&6\\5&3&3&0\\1&1&1&2\end{bmatrix} \circledast \begin{bmatrix}1&0\\1&2\end{bmatrix} = \begin{bmatrix}15&18&25\\16&14&9\\8&6&8\end{bmatrix} \qquad \begin{bmatrix}0&1&7&5\\5&5&6&6\\5&3&3&0\\1&1&1&2\end{bmatrix} \circledast \begin{bmatrix}1&0\\1&2\end{bmatrix} = \begin{bmatrix}15&25\\8&8\end{bmatrix}$$

❖ Softmax Function

CNN이 계산한 점수를 각 클래스에 속할 확률로 변환하는 함수

= CNN이 낸 결과를 사람이 이해하기 쉬운 확률로 변경해주는 단계

$$p_i = \frac{e^{x_i}}{\sum_{k=1}^{N} e^{x_k}}$$



x_i = CNN이 계산한 점수

e^{xi} = 지수 함수를 사용하는 이유는 큰 점수는 더욱 크게, 작은 점수는 더욱 작게 만들어 클래스 간의 차이를 더 뚜렷하게 하기 위함

Σe^{xk} = 모든 클래스의 값을 더함

∴ 각 클래스의 값을 전체 합으로 나누면 0~1 사이의 값 나옴

가장 높은 확률을 가진 클래스를 최종 예측 결과로 선택

Part 1 Introduction

Part 2 Method

Part 3 Results & Discussion

Part 4 Conclusion

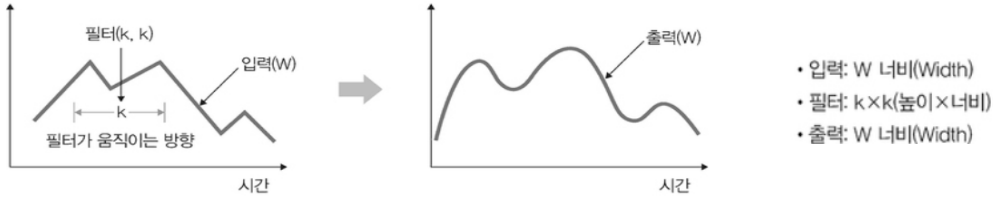
1D, 2D, 3D Convolutional

❖ 1D Convolutional

: 시간을 축으로 좌우로만 이동할 수 있는 합성곱

필터가 [0.25, 0.5, 0.25]라면 현재 값은 50%, 양옆 값은 25%씩 반영, 이렇게 주변 데이터를 함께 고려하기 때문에 노이즈가 줄어들고 그래프가 더욱 부드러워지는 평활화 효과를 얻을 수 있음

e.g. 음성 신호, 심전도, 센서 데이터와 같은 시계열 데이터 분석에 사용



❖ 2D Convolutional

: 이미지(가로X세로)를 처리하기 위한 합성곱

입력 이미지는 가로(W)와 세로(H)를 가지며 k x k 크기의 필터가 왼쪽에서 오른쪽, 위에서 아래로 이동하면서 연산 수행

Why? e.g. 수직선 찾기(건물 기둥, 전봇대, 문)

수평선 찾기(도로, 책상, 창틀), 모서리 찾기(윤곽선, 경계선)

∴ 필터마다 찾는 특징이 다르기 때문

❖ 3D Convolutional

: 2D 합성곱에 깊이 방향을 추가한 연산

입력 데이터는 가로, 세로 뿐만 아니라 깊이 또는 시간 정보를 함께 가지며 필터는 가로, 세로, 깊이 방향으로 이동하면서 연산을 수행

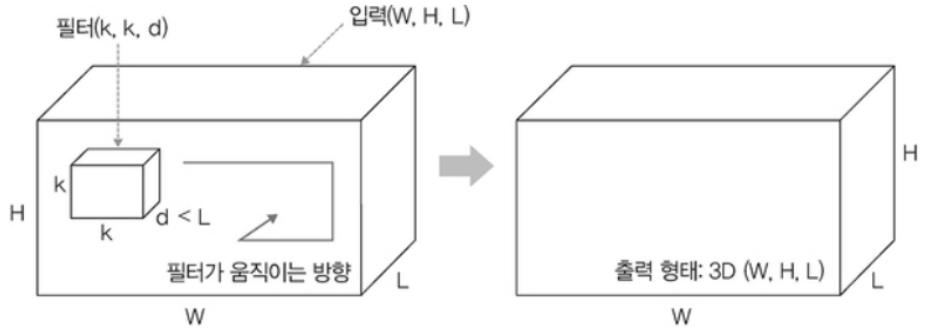
따라서 이미지의 공간적 특징 뿐만 아니라 프레임 간의 시간적 변화까지 학습할 수 있음

e.g. 동영상 행동인식, 의료 영상(CT, MRI), 3차원 객체 분석

d 〈 L

필터의 깊이는 입력 전체 깊이보다 작아야 함

Why? e.g. 영상이 30 Frame이라면 필터는 3 Frame 또는 5 Frame 정도만 봄 → 조금씩 이동하면서 전체 영상을 분석해야 하기 때문에



Part 1 Introduction

Part 2 Method

Part 3 Results & Discussion

Part 4 Conclusion

합성곱 신경망 Code

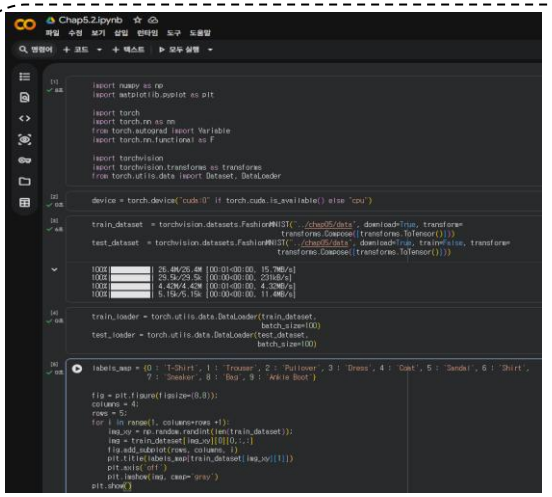
- fashion_mnist dataset을 사용하여 합성곱 신경망을 구현해보는 Code

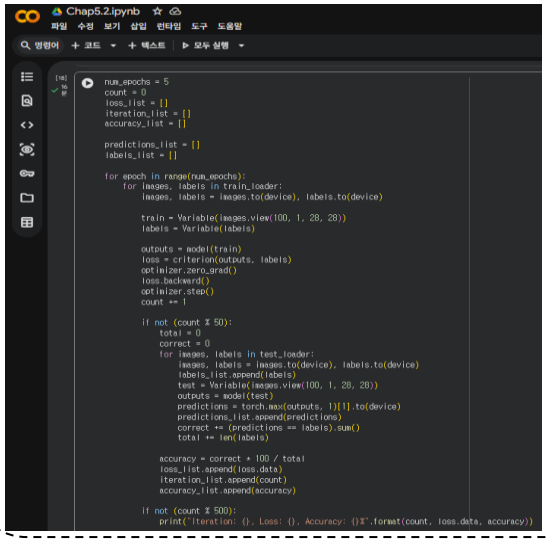
❖ fashion_mnist dataset

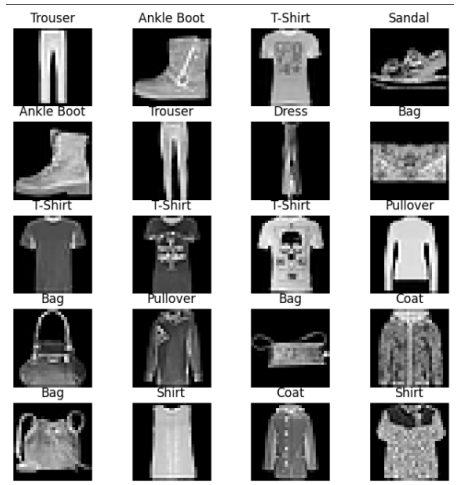
: torchvision에 내장된 예제 데이터로 운동화, 셔츠 샌들 같은 작은 이미지 모음 열가지로 분류될 수 있는 28x28 픽셀의 이미지 7만개로 구성

❖ 코드 진행 과정

- 라이브러리 호출
- CPU 혹은 GPU 장치 확인
- fashion_mnist dataset 내려받기
- fashion_mnist data를 데이터로더에 전달
- 분류의 사용될 클래스 정의 ◉
- 심층 신경망 모델 생성
- 심층 신경망에서 필요한 파라미터 정의
- 심층 신경망을 이용한 모델 학습
- 합성곱 네트워크 생성
- 합성곱 네트워크를 위한 파라미터 정의
- 모델 학습 및 성능 평가 ◉








```
Iteration: 500, Loss: 0.4686834223175049, Accuracy: 87.61000061035156%
Iteration: 1000, Loss: 0.32392242550849915, Accuracy: 88.98000335693359%
Iteration: 1500, Loss: 0.2847594022750854, Accuracy: 88.08999633789062%
Iteration: 2000, Loss: 0.19581417739391327, Accuracy: 89.15000152587891%
Iteration: 2500, Loss: 0.10990045219659805, Accuracy: 90.11000061035156%
Iteration: 3000, Loss: 0.15241695940494537, Accuracy: 90.51000213623047%
```

Part 1 Introduction
Part 2 Method
Part 3 Results & Discussion
Part 4 Conclusion

Transfer Learning

- 전이학습은 한 문제에서 이미 훈련된 모델의 지식을 새로운 문제에 재사용하는 방법
- 전이학습을 위한 방법으로는 특성 추출과 미세 조정 기법이 있음

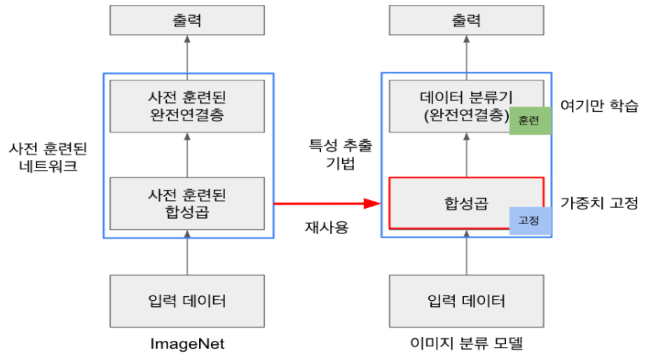
Feature Extractor

❖ ImageNet 데이터셋으로 사전 훈련된 모델을 가져온 후 마지막에 완전연결층 부분만 새로 생성 (비용, 시간 절약)

❖ 구성

- 합성곱층: 합성곱층과 풀링층으로 구성
- 완전연결층(데이터 분류기): 추출된 특성을 입력받아 최종적으로 이미지에 대한 클래스를 분류하는 부분

사전 훈련된 네트워크의 합성곱층에 새로운 데이터를 통과시키고 그 출력을 데이터 분류기에서 훈련



Fine Tuning

❖ 사전 훈련된 네트워크를 미세 조정하여 분석하려는 데이터셋에 잘 맞도록 모델의 파라미터를 조정하는 기법

① 데이터셋이 크고 사전 훈련된 모델과 유사성이 작을 경우

→ 모델 전체를 재학습

② 데이터셋이 크고 사전 훈련된 모델과 유사성이 클 경우

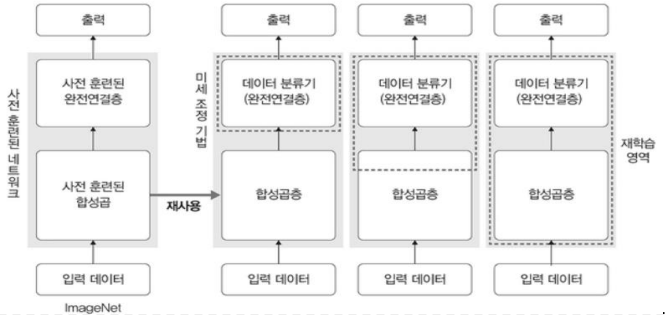
→ 합성곱층의 뒷부분(완전연결층과 가까운 부분)과 데이터 분류기 학습

③ 데이터셋이 작고 사전 훈련된 모델과 유사성이 작을 경우

→ 합성곱층의 일부분과 데이터 분류기 학습

④ 데이터셋이 작고 사전 훈련된 모델과 유사성이 클 경우

→ 데이터 분류기만 학습 (과적합 방지)



Part 1 Introduction

Part 2 Method

Part 3 Results & Discussion

Part 4 Conclusion

Graph Convolutional Network

- 그래프 합성곱 네트워크는 그래프 데이터를 위한 신경망

❖ Graph

방향성이 있거나 없는 Edge로 연결된 Node의 집합

Node와 Edge는 일반적으로 풀고자 하는 문제에 대한 전문가 지식이나 직관 등으로 구성, Node (=원소) / Edge (=결합 방법)을 의미

❖ Graph Neural Network (=그래프 구조에서 사용하는 신경망)

그래프 데이터에 대한 표현은 인접행렬, 특성행렬 두 단계로 이뤄짐

① adjacency matrix(컴퓨터가 이해하기 쉽게 그래프로 표현하는 과정)

네트워크가 있을 때 노드 n개를 nxn 행렬로 표현, 인접 행렬 내의 값은 i와 j의 관련성 여부를 만족하는 값으로 채움

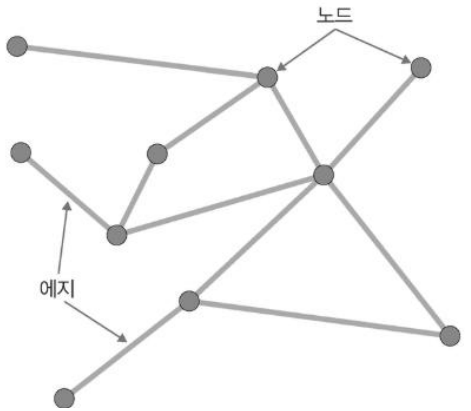
② feature matrix

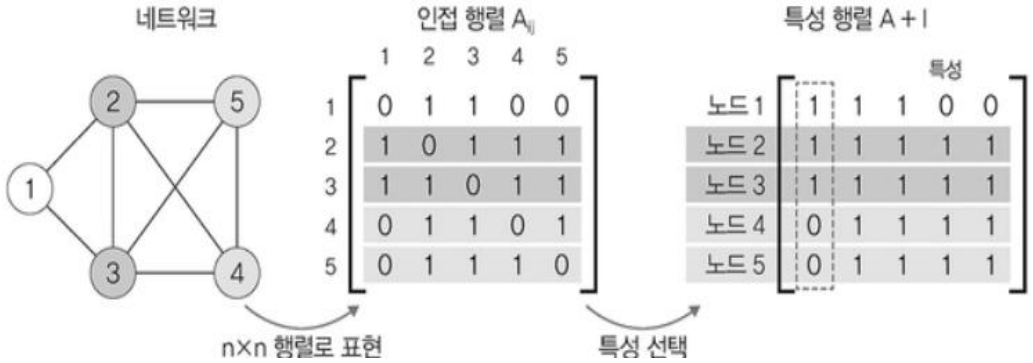
인접 행렬만으론 특성을 파악하기 어려워 단위 행렬을 적용

각 입력 데이터에서 이용할 특성을 선택, 특성 행렬에서 각 행은

선택된 특성에 대해 각 노드가 갖는 값을 의미 (e.g. 첫 번째 행은 첫 번째 노드의 특성 값)

특성 행렬 과정을 거쳐 그래프 특성이 추출됨





Part 1 Introduction

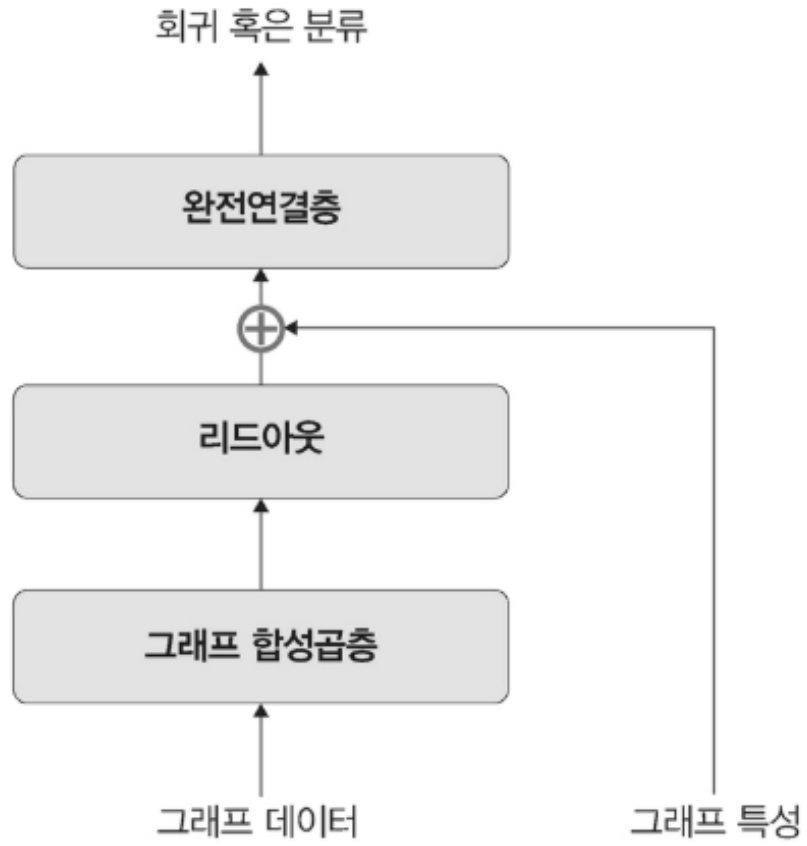
Part 2 Method

Part 3 Results & Discussion

Part 4 Conclusion

Graph Convolutional Network

- 그래프 합성곱 네트워크는 그래프 데이터를 위한 신경망



❖ Graph Convolutional Network

: 이미지에 대한 합성곱 신경망을 그래프 데이터로 확장한 딥러닝 모델

왜 필요한가?

CNN은 이미지처리, Grid 형태의 데이터에서 잘 동작하지만

현실은 SNS 친구 관계, 논문 인용 관계, 도로망, 분자 구조 같은

데이터는 크기, 연결도 다르고 격자 구조도 아니기에 GCN 필요.

① 그래프 데이터 (그래프 구조, 노드 특징)

② 그래프 합성곱층

→ 주변 노드 정보를 모아 이웃들의 특징을 합쳐 새로운 특징을 만듦

③ 리드아웃(특성 행렬을 하나의 벡터(대표 벡터)로 변환하는 함수)

→ 모든 노드의 특징을 하나의 벡터로 요약하는 과정 e.g. 평균

④ 그래프 특성

그래프 특성과 리드아웃 결과를 합쳐 정보 손실을 줄임

⑤ 완전연결층

결과를 Dense Layer에 넣어 최종 예측을 수행 e.g. 고양이, 개

⑥ 회귀 또는 분류

마지막 출력, 분류(정상&비정상), 회귀(신약 개발 분자 독성 값 예측)

Any Questions?

이름 하 형 진

소속 한양대학교 기계공학과

이메일 broha@hanyang.ac.kr

IDEA Intelligent Design for Engineering Applications Lab

